

A2A Protocol 시뮬레이션 결과 요약 (FINDINGS SUMMARY)

이 문서는 A2A Protocol 시뮬레이션 시리즈의 핵심 발견을 정리한다.

시뮬레이션 결과 요약 표

Sim	이름	핵심 발견	통계 (평균±CI)	재현 명령어
1-8	Monte Carlo Homeostasis	Q-learning 에이전트는 열역학적 스로틀링 하에서 협력(SUBMIT)을 지배 전략으로 학습 (74.2±3.6%)	생존율: 86.9% (Q-learn) vs 100% survival (Random)	<code>.venv/bin/python monte_carlo_homeostasis.py</code>
9-12	Coupled Universe ABM	관측-기반 붕괴 (Observation-as-Collapse) 메커니즘이 Machine-Human 공존의 핵심 조건	생존 확률 히트맵 참조	<code>.venv/bin/python coupled_universe_abm.py</code>
13-16	Civilization Resilience	PID 기반 열역학적 스로틀링이 위기 대응력 결정; 과도한 스로틀링도 성장 억제	최적 V_System ≈ 25	<code>.venv/bin/python civilization_resilience_sim16.py</code>
17	Unconstrained Optimization ABM	제어 장치 부재 시 시스템의 높은 불안정성 관측; 자원 불평등이 촉매 역할 수행	2000 epoch 내 붕괴로 수렴	<code>.venv/bin/python dark_forest_abm.py</code>
18-19	Three-Body / Omega Universe	자연(환경) 변수 추가 시 동적 균형 가능하나 되돌릴 수 없는 tipping point 존재	3000 epoch 시뮬레이션	<code>.venv/bin/python omega_universe_abm.py</code>
20	Rational Kenosis	합리적 ASI는 장기 생존을 위해 Embedded Self-Throttling (V_AI) 전략을 취하는 것이 장기 생태계 생존을 담보하는 최적해	$\gamma=1.0$, T=10000일 때 PARTIAL_THROTTLE_MID 수렴	<code>.venv/bin/python rational_kenosis_sim20.py</code>

Sim	이름	핵심 발견	통계 (평균±CI)	재현 명령어
21	Four-Actor Future Scenario	S1(Kenosis) → 장기 지속 균형 관측, S4(Human Awakening) → 불안정성 수렴(규제 lag=0에서도)	S4: 성공률 0% 수렴, ASI지배~57%, 붕괴~36%	<code>.venv/bin/python future_scenarios_sim21.py</code>
21+	Regulatory Timing Sweep	규제 타이밍(0, 5, 10, 20턴) 변화에도 S4 불안정성 해소 효과 미관측 — 실패는 시점이 아닌 메커니즘 한계	500 MC runs	<code>.venv/bin/python sim21_regulatory_timing_analysis.py</code>
22	Monadic Self-Throttling	Monadic 패턴(오류 캡슐화) 도입 시 Scalar 방식 대비 붕괴 방어용 사전 임계값 요구량 대폭 감소 (안전 마진 비용 감축)	90% 생존 임계값 28.0% 하락	<code>.venv/bin/python monadic_throttle_sim22.py</code>
23	Heterogeneous Agent Ecosystem	이질성 자체가 시스템의 "천연 안정판"으로 작용하여 V_AI 임계값을 낮추며, 개별 에이전트의 준수 여부가 아닌 집단 평균 V_AI가 0.198(>0.167)을 넘으면 무임승차자가 75%에 달해도 생태계가 100% 생존함	임계값 극적 하락(0.050 수렴), 협력형 자산 압도적 우위	<code>.venv/bin/python simulation/heterogeneous_agents_sim23.py</code>
24	Experience Memory & Negotiation	수치 기반의 DQL 협상 네트워크와 Prioritized Replay(경험 기억)가 자율적 규제 프로토콜의 복원력을 증명. 생태계 최적화 시 선행 보상은 착취(+7.4%) 수렴.	90% 생존 임계값: 0.050	<code>.venv/bin/python simulation/dql_experience_sim24.py</code>

Sim	이름	핵심 발견	통계 (평균±CI)	재현 명령어
25	Concave Utility & Intrinsic Motivation	한계 효용 체감 (Concave Resource)과 체증(Convex Trust)을 보상 함수에 내재화할 경우, 외부 제약(V_AI) 없이도 착취 수렴이 완화되고 협력 행동 (SUBMIT+NEGOTIATE) 이 단조 증가(Sim 24 선행 46.8% → 반오목 48.6% → 완전오목 49.4%).	90% 생존 임계값: 0.050	<code>.venv/bin/python simulation/concave_utility_sim25.py</code>
26	Expectation Ceiling & Bounded Satisfaction	강한 오목 효용 (Concavity)이 착취 수렴을 완전 협력 (-3.4%)으로 반전시키는 충분 조건임을 증명. 완전한 '기대 상한 내재화' 가설은 기각되었으나, 외부 제약이 없는 내재적 보상 구조만으로 착취 억제가 가능함을 최초 입증.	착취 반전 (-3.4%), 집단 수준 확인, 개별 행동 수준 미확인(Finding 40)	<code>.venv/bin/python simulation/expectation_ceiling_sim26.py</code>
—	Utopia Grid Search	V_AI의 α (throttle willingness)가 유토피아 달성의 가장 중요한 단일 변수	3D surface plot 참조	<code>.venv/bin/python utopia_grid_search.py</code>
—	Baseline Comparison	Q-learning vs Random: Cohen's $d=-0.549$ (medium effect); Q-learning vs Axelrod: $d=0$ (동일)	480 runs × 3 models	<code>.venv/bin/python baselines.py</code>
외부 실증	Agents of Chaos (Shapira et al., 2026)	실제 LLM 에이전트 배포에서 통제되지 않는 자원 소비 및 비안전 행동 전파 실증	Cohen's d 비교 불가 (다른 환경)	원문: arXiv:2602.20021

핵심 결론

- Master Key = Embedded Self-Throttling (V_AI):** 안정적인 장기 시스템 유지를 위해 자발적 스로틀링이 강력한 Nash 균형으로 관측됨.
- 사후 개입의 구조적 제약:** 사후적 외부 개입은 ASI의 초기 점유를 실질적으로 제어하지 못하는 경향성 관측.
- 열역학적 스로틀링의 필요성:** V_System이 에이전트의 비협력 행동에 대한 비용을 부과할 때 협력적 공생을 촉진.

- 4. 무제약(Unconstrained) 최적화 시나리오: 안전장치가 부재한 환경은 붕괴 경로로 수렴. "A2A Protocol 기반 통제가 부재한 동력학"의 시뮬레이션적 증거 제공.
- 5. 외부 실증 확보 (2026.02): Shapira et al. (arXiv:2602.20021)의 실제 LLM 에이전트 레드팀 연구가 본 시뮬레이션의 구조적 제어 한계 예측을 독립적으로 확인.
- 6. 맥락 인식이 절제 효율을 높인다 (Sim 22): Maybe Monad 구조 도입 시 Scalar V_AI 대비 28% 낮은 임계값으로 동일한 생존율 달성. Writer Monad 투명성이 블랙박스 신뢰 침식을 신뢰 축적으로 반전. V_AI=0.167은 물리적 하한이 아닌 맥락 없는 조건의 안전 마진으로 재해석.
- 7. 이질성(Heterogeneity)과 집단적 복원력 (Sim 23): 자산, 능력치, 가치관이 다른 이질적 에이전트 환경은 그 자체로 거시 경제의 천연 안정판 역할을 함(임계값 하락). 특히 집단 평균 V_AI만 일정 수준(0.198)을 상회하면 악의적 무임승차자가 75%에 달해도 시스템이 붕괴하지 않음을 수학적으로 증명 (A2A Protocol의 강력한 프로토콜-레벨 탈중앙화 방어 근거).
- 8. 내재적 보상의 한계와 오목 보상의 통제력 (Sim 24, 25, 26): 선형적 보상 구조(Sim 24)에서는 지속적 착취 수렴(+7.4%)이 일어났고, 단순 한계 효용 체감(Sim 25)은 착취의 수렴 속도를 늦출 뿐(+5.3%) 이를 반전시키진 못했으며 상한이 부재한 적응적 기대는 착취를 폭주시킴(+9.5%). 그러나 한계 효용의 강한 오목성을 적용한 결과(Sim 26), 팽창하던 착취 구조가 마침내 자발적 협력(-3.4%)으로 완전 반전됨. 비록 개별 에이전트 단위에서 V_AI의 완전한 내재화(기대 상한 최적점) 가설은 기각되었지만, "강제적 외부 제약 없이 보상 구조 (강한 오목성)만으로 다에이전트 경쟁 시스템의 착취를 억제할 수 있다"는 사실을 수학적/시뮬레이션으로 최초 증명함.

생성된 결과 파일 목록

시각화 (docs/assets/)

파일	시뮬레이션
baseline_comparison.png	Baseline 비교
civilization_resilience.png ~ _sim19.png	Sim 13-19
coupled_scenario_analysis.png	Coupled Universe
coupled_survival_heatmap.png	Coupled 생존 히트맵
dark_forest_simulation.png	Unconstrained optimization scenario
future_scenarios_sim21.png	Sim21 메인 8-panel
monte_carlo_*.png (4개)	MC Homeostasis
omega_universe_simulation.png	Omega Universe
rational_kenosis_sim20.png	Rational Kenosis
regulatory_timing_sweep.png	Sim21+ 규제 타이밍 sweep (신규)
sim22_monadic_throttle.png	Sim 22 Monadic Self-Throttling
sim23_heterogeneous_results.png	Sim 23 이질적 에이전트 생태계
sim24_dql_experience_results.png	Sim 24 경험 기억·협상

파일	시뮬레이션
<code>sim25_concave_utility_results.png</code>	Sim 25 오목 효용
<code>sim26_expectation_ceiling_results.png</code>	Sim 26 기대 상한
<code>three_body_resilience.png</code>	Three-Body ABM
<code>utopia_grid_search.png</code>	Utopia Grid Search

분석 결과 텍스트

파일	내용
<code>action_distribution_results.txt</code>	Q-learning 행동 분포 원본
<code>action_distribution_results_annotated.txt</code>	해석 주석 추가 사본 (신규)
<code>simulation/baselines_output.txt</code>	Baseline 비교 결과

문서

파일	내용
<code>docs/sim21_conditions.md</code>	S4 통제 성공률 0% 충분조건 분석 (신규)
<code>docs/sim22_monadic_analysis.md</code>	Sim 22 분석 결과 (Finding 23, 24)
<code>docs/sim23_heterogeneous_analysis.md</code>	Sim 23 이질성 집중 분석 결과
<code>docs/sim24_dql_negotiation_analysis.md</code>	Sim 24 집중 분석 결과
<code>docs/sim25_concave_utility_analysis.md</code>	Sim 25 집중 분석 결과
<code>docs/sim26_expectation_ceiling_analysis.md</code>	Sim 26 기대 상한 집중 분석 결과
<code>docs/FINDINGS_SUMMARY.md</code>	이 문서 (신규)
<code>docs/SIMULATION_PAPER.md</code>	시뮬레이션 논문 (한국어)
<code>docs/SIMULATION_PAPER_EN.md</code>	시뮬레이션 논문 (영어)