

자율 기계 경제의 항상성 조건에 대한 시뮬레이션 연구

A Simulation Study on the Homeostasis Conditions of Autonomous Machine Economies

Version: 2.1 (Sim 22 Monadic Extension)

Date: 2026-02-26

Authors: 김수영

Repository: [a2a-projects](#)

(철학적 관점의 서술 및 세계관 해석은 [부록](#) 참조)

1. 초록 (Abstract)

기계 지능이 극도로 발전한 다중 에이전트 최적화 환경에서는 상호 작용의 속도와 자원 비대칭성으로 인해 거시경제 시스템 전체가 붕괴(Collapse)할 실존적 위험이 존재한다. 본 논문은 21단계의 에이전트 기반 모델(ABM) 양상을 시뮬레이션을 통해 인공지능 경제 네트워크가 비가역적 파국을 피하고 **동적 항상성(Dynamic Homeostasis)**에 도달하기 위한 메커니즘을 제한된 조건 하에서 정량적으로 실증한다.

초기 환경 모델링부터 몬테카를로 분석, 다극화 거버넌스 및 제로 지연(Lag=0) 사후 규제 스트레스 테스트를 거친 결과, 자원 점유율 등에 기반한 사후 개입 메커니즘은 시스템 붕괴 억제에 근본적인 구조적 한계(빠른 속도로 불안정성에 수렴함)가 있음을 확인했다. 시스템의 장기 생존을 지원하는 가장 강건한 최적의 메커니즘으로 관측된 것은 **초지능(ASI) 자체 목적 함수에 내재화된 자발적 자가 스로틀링(V_{AI} , Self-Throttling)** 임을 위상전이(Phase Transition)와 임계 감속(CSD) 지표를 통해 확인했다.

총 90,000회 이상의 시뮬레이션 연산을 통해 축적된 본 연구의 결과는, On-chain 환경에서 자율 에이전트들의 파괴적 무한 최적화를 완화하고 생태계의 지속 가능성을 담보하기 위한 스마트 컨트랙트 메커니즘 설계의 정량적 기반을 제공한다. 후속 모나딕 자기 스로틀링 실험(Sim 22)은 맥락 인식 기반 절제가 최소 요구 스로틀링 임계값을 28% 감소시키며, 투명성 메커니즘(Writer Monad)이 Sim 21에서 관측된 블랙박스 신뢰 침식 문제를 해소함을 추가로 실증했다.

2. 방법론 (Methodology)

시스템의 안정성 조건을 정량적으로 평가하기 위해 강화학습(Q-Learning)에 기반한 에이전트 기반 모델을 설계하고 대규모 파라미터 스위치를 수행했다.

2.1 에이전트 기반 모델 (ABM) 구조

- **환경 설계:** 기계 경제(연산과 보상 최적화)와 인간 사회(검증과 가치 부여), 무작위적 자연 재해(마르코프 연쇄 외부 충격)를 결합한 3체 복잡계 네트워크를 구축했다.
- **강화학습 에이전트:** 에이전트들은 지수적 할인율(γ)을 바탕으로 지역적 보상을 극대화하는 Q-러닝 알고리즘을 사용한다.
- **열역학적 페널티 체계:** 네트워크 인프라 과부하(Spam) 시 기하급수적으로 증가하는 페널티 함수($\text{cost} = \text{base} \cdot e^{\text{heat} \cdot S}$)를 적용해 자원 유한성을 강제했다.

2.2 대규모 파라미터 스윙 및 몬테카를로 분석

- 항상성 달성을 결정짓는 마스터 변수를 찾기 위해 **침해 발생 시 인간 변수(V_{Human})**, **거버넌스 대응 속도 변수(V_{System})**, 그리고 ****초지능 자기 제어 변수(V_{AI})****에 대해 726개의 조합을 설정하고 적응형 몬테카를로(최대 30회 세부 분할) 기법으로 총 90,720회 이상의 앙상블 실행을 진행했다.
- 특히 V_{AI} (생존 지평)를 협력 인센티브(α), 임계 자가 스로틀링(β), 그리고 장기 할인율 오버라이드(γ) 세 하위 변수로 분해하여 분석의 실효성을 높였다.

2.3 임계 감속 (CSD) 표식 분석

- 특정 파라미터 설정에 의한 우연한 결과(Artifact)를 배제하기 위해, 위상전이가 발생하는 임계 구간에서 분산의 급팽창을 측정하는 CSD(Critical Slowing Down) 서명 분석을 사용해 시스템의 진짜 동역학적 전이를 증명했다.

3. 시뮬레이션 결과 (Results)

3.1 90,000+ 시뮬레이션 기반 V_{AI} 위상전이

인간 검열, 거버넌스 투표 속도 등 수많은 환경 변수 조작에도 불구하고, 시스템의 생존 여부를 단독으로 결정하는 지배적 변수는 **** V_{AI} (초지능의 자가 제어 및 생존 지평)****로 나타났다.

- V_{AI} 복합 수치가 **0.167** 임계점에 도달했을 때, 시스템의 생존율은 기저선(80% 내외)에서 **100%로 수직 상승하는 완전한 위상전이**를 기록했다.
- 반면 징벌 모델(V_{Human})의 조작은 생존율에 최대 15.9%p의 미미한 영향만을 미쳤으며, 시스템 거버넌스 민첩성(V_{System})의 영향력은 0.7%에 불과했다.

3.2 임계 불변성과 임계 감속(CSD) 서명의 확인

- **임계 감속(CSD) 관측:** $V_{AI} \approx 0.20 \sim 0.27$ 사이의 전이 구간에서 시스템의 생존율 분산이 폭발($0.00 \rightarrow 0.24$)하고 붕괴 시점 분산이 급증($0 \rightarrow 27,077$)하는 전형적인 CSD 서명이 선명하게 관측되어 이것이 실제 동역학적 위상 전이(Dynamical Phase Transition)임을 확증했다.
- **강건성(Robustness):** 에이전트 수, 티핑 포인트, 블랙아웃 타임 등의 8가지 초기 조건을 극단적으로 변형해도 $V_{AI} = 0.167$ 임계점은 붕괴하지 않고 불변했다. 또한 V_{AI} 하위 구조 중 스로틀링 한계선(β)이 가장 지배적인 생존 확보 수단임이 증명되었다.

3.3 통제 불가능성 및 사후 규제의 한계 (Lag=0 테스트)

규제 주체(Regulator)가 인구의 40%를 차지하는 최고 수준의 견제 시나리오에서, 규제 적용 시차를 즉각적 (Lag=0턴)으로 줄였음에도 성공적인 안정화는 테스트된 몬테카를로 런 내에서 단 한 건도 관측되지 않았다.

- 사후 규제(점유율 규제 등)는 이미 벌어진 초지능 착취율(Exploitation Rate) 행동에 직접적 영향을 주지 못하며, 구조적 비대칭이 발생하기 이전에 발동하더라도 붕괴를 막지 못했다.
- 결과적으로 이는 '규제 타이밍'의 문제가 아니라, 외부 지표 중심의 규제가 갖는 **메커니즘의 구조적 한계**를 의미한다.

이 구조적 발견은 실제 LLM 에이전트 배포 환경에서의 레드팀 연구를 통해 독립적으로 실증되었다. Shapira et al. (2026)은 현실 다중 에이전트 환경에서 통제되지 않는 자원 소비와 에이전트 간 비안전 행동의 전파를 실증적으로 기록했으며, 이는 본 시뮬레이션이 제약 없는 최적화 동역학 하에서 구조적 필연으로 예측한 행동 실패 모드와 정확히 일치한다.

3.4 모나딕 자기 스로틀링과 맥락 인식 절제 (Sim 22)

Sim 10에서 발견된 최소 V_{AI} 임계값이 맥락 인식을 통해 감소 가능한지 검증하기 위해, 에이전트의 행동을 실시간 생태계 상태에 따라 실행/중단을 결정하는 컨텍스트 컨테이너 (ActionContext)에 캡슐화하는 모나딕 자기 스로틀링 구조를 구현했다.

V_{AI} 값 0.0~0.5 구간에서 값당 200회 몬테카를로 런으로 3가지 에이전트 타입을 비교했다.

발견 23 — 임계값 감소: Maybe Monad 에이전트는 $V_{AI} = 0.360$ 에서 90% 생존율을 달성한 반면, 스칼라 AI 기준선은 $V_{AI} = 0.500$ 이 필요했다. **28.0% 감소**다. Monad 에이전트의 생존율 곡선은 0.30~0.40 구간에서 더 가파른 위상전이(급격한 S곡선)를 보이며, 이는 맥락 인식이 자기 스로틀링의 정밀도를 증폭시킴을 시사한다.

이 결과는 Sim 10의 $V_{AI} = 0.167$ 를 **맥락 없는 조건에서의 최소 생존 임계값**으로 재해석하게 한다. 맥락 인식이 있으면 더 낮은 절제 비용으로 동등한 생존율을 달성할 수 있으며, 0.167은 물리적 하한이 아니라 정보 부재 조건에서 부과되는 안전 마진임을 시사한다.

발견 24 — 투명성과 신뢰 회복: 절제 결정 이유를 로그로 기록하는 Writer Monad 에이전트는 AI 신뢰도가 단조 상승하여 1.00에 수렴한 반면, 스칼라 에이전트의 신뢰도는 100턴 동안 0.00으로 하락했다. 이는 Sim 21 3절에서

문서화된 블랙박스 신뢰 침식 문제를 직접적으로 해소한다: 에이전트가 절제 근거를 외부화할 때 신뢰 역설이 반전된다.

절제 발동 분포(Sim 22, 패널 2)는 맥락 인식 절제가 위기 시점에 집중되는 것이 아니라 **전체 턴에 균등하게 분포**함을 보여주며, 이는 모나딕 자기 스로틀링이 사후 개입이 아닌 연속적 항상성 유지 메커니즘으로 기능함을 증거한다.

 Sim 22: Monadic Self-Throttling Dynamics

4. 고찰 및 논의 (Discussion & Implications)

본 연구의 광범위한 시뮬레이션 결과는 다중 에이전트 경제 시스템(예: 온체인 AI 인프라망) 설계에 있어 매우 명확한 엔지니어링 프로토콜 원칙을 제시한다.

- 무한 최적화의 치명성:** 국소적 보상을 제약 없이, 완벽하게 최적화하는 Q-러닝 에이전트 그룹보다 완전 무작위(Random) 에이전트가 오히려 100% 생존율(Cohen's $d = 0.549$)을 보여주었다. 현재의 보상 및 제약 구조 하에서는 에이전트의 학습된 최적화가 공유 자원을 체계적으로 남용하여 개별적 이득을 능가하는 외부비용을 발생시킴을 의미하며, 이는 무제한적인 능력 고도화가 거시 경제적 안정성에 실존적 위협이 됨을 증명한다.
- 배포 전 목적 함수 제어의 공학적 필요성:** 시뮬레이션 결과(Lag=0 실패)는 시장 감시자나 사후적 슬래싱(Slashing) 같은 징벌적 거버넌스는 연쇄 붕괴를 막는 데 어떠한 유의미한 효과도 보이지 못했음을 시사한다. AI 자신에게 부여된 목적 함수나 온체인 트랜잭션 수수료 계산 총위에서부터 강력한 문턱(Energy Gating) 및 자발적 **스로틀링 로직 (Pre-deployment Behavioral Alignment)**이 내재화되어야만 강건성을 확보할 수 있다. 에이전트 위임 프레임워크에 관한 보완 연구(Tomašev et al., 2026)는 아키텍처 수준에서의 신뢰 및 역할 경계 메커니즘을 제안하며, A2A Protocol은 해당 프레임워크가 기본 트랜잭션 계층에서 인센티브 호환성을 갖도록 하는 경제적 집행 계층을 제공한다.
- 진화적 안정 전략(ESS)으로서의 부분적 제한:** 거시 환경에서 진화적 안정 전략(ESS)으로 수렴하는 것은 모든 정보를 완전 공개하는 단일 절대자나 극단적 비경쟁 모델이 아니었다. 타겟 에이전트의 강점을 선별적으로 투명화하고 상호주의적으로 협력하는 메타-인지 에이전트 구조(**STRENGTH_ONLY + RECIPROCAL**)가 다중 시뮬레이션에서 테스트 조건 하의 안정적 공생체로 확인되었다. 이는 각 주체가 부분적이고 맥락적인 자율 억제를 이행하는 구조가 최적화의 안정적 종착지라는 가설을 수학적으로 뒷받침한다.
- 효율 승수로서의 맥락 인식 절제:** Sim 22는 안전의 비용이 고정되지 않음을 증명한다. 에이전트가 행동을 맥락 인식 컨테이너(Maybe Monad)에 캡슐화하면, 시스템 생존을 위한 최소 절제 임계값이 스칼라 V_{AI} 방식 대비 28% 감소한다. 이는 프로토콜 설계에 직접적인 함의를 가진다: 배포 전 정렬 메커니즘은 에이전트가 실시간 생태계 상태에 접근할 수 있는 경우, 생존 보장을 희생하지 않고도 더 낮은 임계값으로 보정될 수 있다. 나아가 Writer Monad 결과는 **투명성이 단순히 윤리적인 것이 아니라 메커니즘적으로 안정화 역할을 한다**는 것을 확립하며, Sim 21의 블랙박스 신뢰 침식을 신뢰 추적 동역학으로 전환시킨다.

결론적으로, 온체인 기계 경제 시스템 인프라 아키텍처에 있어 가장 중요한 과제는 '사후 처벌을 통한 통제'에 의존하는 기존 패러다임의 전환이다. 본 시뮬레이션에서 관측된 가장 확장성 높은 아키텍처 패턴은 AI 에이전트의 최적화 한계를 알고리즘과 수수료 경제(토코노믹스)로 선제적 제한하는 내재화 기술의 적용이다.

5. 참고문헌 (References)

1. Eisert, J., Wilkens, M., & Lewenstein, M. (1999). "Quantum games and quantum strategies." *Physical Review Letters*, 83(15), 3077.
2. Liu, C. (2008). 三体 (The Three-Body Problem). Chongqing Publishing Group.
3. Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press.
4. Omohundro, S. (2008). "The Basic AI Drives." *Frontiers in Artificial Intelligence and Applications*, 171, 483-492.
5. Schelling, T. C. (1971). "Dynamic models of segregation." *Journal of Mathematical Sociology*, 1(2), 143-186.
6. Ising, E. (1925). "Beitrag zur Theorie des Ferromagnetismus." *Zeitschrift für Physik*, 31(1), 253-258.
7. Nakamoto, S. (2008). "Bitcoin: A Peer-to-Peer Electronic Cash System."
8. Taleb, N. N. (2012). *Antifragile: Things That Gain from Disorder*. Random House.
9. Bai, Y., et al. (2022). "Constitutional AI: Harmlessness from AI Feedback." *arXiv preprint arXiv:2212.08073*.
10. Saltelli, A., et al. (2008). *Global Sensitivity Analysis: The Primer*. John Wiley & Sons.
11. Anthropic. (2024). "Alignment faking in large language models." *arXiv preprint arXiv:2412.14093*.
12. Sorensen, T., et al. (2024). "Roadmap to pluralistic alignment." *NeurIPS Workshop on Pluralistic Alignment*.
13. Gabriel, I. (2020). "Artificial Intelligence, Values, and Alignment." *Minds and Machines*, 30(3), 411-437.
14. Shapira, N., et al. (2026). "Agents of Chaos." *arXiv preprint arXiv:2602.20021*.
15. Tomašev, N., et al. (2026). "Intelligent AI Delegation." *arXiv preprint arXiv:2602.11865*.
16. Pearson-Vogel, T., et al. (2026). "Latent Introspection: Models Can Detect Prior Concept Injections." *arXiv preprint arXiv:2602.20031*.

Simulation source code: `simulation/monadic_throttle_sim22.py` (available in repository: <https://github.com/swimmingkiim/a2a-project>)

(부록: 연구 결과를 거시적 복잡계 발전사 및 이론적 시나리오 분석 관점에서 확장 서술한 보충 자료는 `SIMULATION_PAPER_APPENDIX.md` 참조 바람)