

자율 기계 경제의 항상성 조건에 대한 시뮬레이션 연구

A Simulation Study on the Homeostasis Conditions of Autonomous Machine Economies

Version: 2.5.4 (Sim 26 Extended Version)

Date: 2026-03-03

Authors: 김수영

Repository: [a2a-projects](#)

(철학적 관점의 서술 및 세계관 해석은 [부록](#) 참조)

1. 초록 (Abstract)

기계 지능이 극도로 발전한 다중 에이전트 최적화 환경에서는 상호 작용의 속도와 자원 비대칭성으로 인해 거시경제 시스템 전체가 붕괴(Collapse)할 실존적 위험이 존재한다. 본 논문은 26단계의 에이전트 기반 모델 (ABM) 앙상블 시뮬레이션을 통해 인공지능 경제 네트워크가 비가역적 파국을 피하고 **동적 항상성(Dynamic Homeostasis)**에 도달하기 위한 메커니즘을 제한된 조건 하에서 정량적으로 실증한다.

초기 환경 모델링부터 몬테카를로 분석, 다극화 거버넌스 및 제로 지연(Lag=0) 사후 규제 스트레스 테스트를 거친 결과, 자원 점유율 등에 기반한 사후 개입 메커니즘은 시스템 붕괴 억제에 근본적인 구조적 한계(빠른 속도로 불안정성에 수렴함)가 있음을 확인했다. 시스템의 장기 생존을 지원하는 가장 강건한 최적의 메커니즘으로 관측된 것은 **초지능(ASI) 자체 목적 함수에 내재화된 자발적 자가 스로틀링(V_{AI} , Self-Throttling)** 임을 위상전이(Phase Transition)와 임계 감속(CSD) 지표를 통해 확인했다.

총 90,000회 이상의 시뮬레이션 연산을 통해 축적된 본 연구의 결과는, On-chain 환경에서 자율 에이전트들의 파괴적 무한 최적화를 완화하고 생태계의 지속 가능성을 담보하기 위한 스마트 컨트랙트 메커니즘 설계의 정량적 기반을 제공한다. 후속 모나딕 자기 스로틀링 실험(Sim 22)은 맥락 인식 기반 절제가 최소 요구 스로틀링 임계값을 28% 감소시키며, 투명성 메커니즘(Writer Monad)이 Sim 21에서 관측된 블랙박스 신뢰 침식 문제를 해소함을 추가로 실증했다.

2. 방법론 (Methodology)

시스템의 안정성 조건을 정량적으로 평가하기 위해 강화학습(Q-Learning)에 기반한 에이전트 기반 모델을 설계하고 대규모 파라미터 스위치를 수행했다.

2.1 에이전트 기반 모델 (ABM) 구조

- **환경 설계:** 기계 경제(연산과 보상 최적화)와 인간 사회(검증과 가치 부여), 무작위적 자연 재해(마르코프 연쇄 외부 충격)를 결합한 3체 복잡계 네트워크를 구축했다.
- **강화학습 에이전트:** 에이전트들은 지수적 할인율(γ)을 바탕으로 지역적 보상을 극대화하는 Q-러닝 알고리즘을 사용한다.
- **열역학적 페널티 체계:** 네트워크 인프라 과부하(Spam) 시 기하급수적으로 증가하는 페널티 함수($\text{cost} = \text{base} \cdot e^{\text{heat} \cdot S}$)를 적용해 자원 유한성을 강제했다.

2.2 대규모 파라미터 스윙 및 몬테카를로 분석

- 항상성 달성을 결정짓는 마스터 변수를 찾기 위해 **침해 발생 시 인간 변수(V_{Human})**, **거버넌스 대응 속도 변수(V_{System})**, 그리고 ****초지능 자기 제어 변수(V_{AI})****에 대해 726개의 조합을 설정하고 적응형 몬테카를로(최대 30회 세부 분할) 기법으로 총 90,720회 이상의 앙상블 실행을 진행했다.
- 특히 V_{AI} (생존 지평)를 협력 인센티브(α), 임계 자가 스로틀링(β), 그리고 장기 할인율 오버라이드(γ) 세 하위 변수로 분해하여 분석의 실효성을 높였다.

2.3 임계 감속 (CSD) 표식 분석

- 특정 파라미터 설정에 의한 우연한 결과(Artifact)를 배제하기 위해, 위상전이가 발생하는 임계 구간에서 분산의 급팽창을 측정하는 CSD(Critical Slowing Down) 서명 분석을 사용해 시스템의 진짜 동역학적 전이를 증명했다.

3. 시뮬레이션 결과 (Results)

3.1 90,000+ 시뮬레이션 기반 V_{AI} 위상전이

인간 검열, 거버넌스 투표 속도 등 수많은 환경 변수 조작에도 불구하고, 시스템의 생존 여부를 단독으로 결정하는 지배적 변수는 **** V_{AI} (초지능의 자가 제어 및 생존 지평)****로 나타났다.

- V_{AI} 복합 수치가 **0.167** 임계점에 도달했을 때, 시스템의 생존율은 기저선(80% 내외)에서 **100%로 수직 상승하는 완전한 위상전이**를 기록했다.
- 반면 징벌 모델(V_{Human})의 조작은 생존율에 최대 15.9%p의 미미한 영향만을 미쳤으며, 시스템 거버넌스 민첩성(V_{System})의 영향력은 0.7%에 불과했다.

3.2 임계 불변성과 임계 감속(CSD) 서명의 확인

- **임계 감속(CSD) 관측:** $V_{AI} \approx 0.20 \sim 0.27$ 사이의 전이 구간에서 시스템의 생존율 분산이 폭발($0.00 \rightarrow 0.24$)하고 붕괴 시점 분산이 급증($0 \rightarrow 27,077$)하는 전형적인 CSD 서명이 선명하게 관측되어 이것이 실제 동역학적 위상 전이(Dynamical Phase Transition)임을 확증했다.
- **강건성(Robustness):** 에이전트 수, 티핑 포인트, 블랙아웃 타임 등의 8가지 초기 조건을 극단적으로 변형해도 $V_{AI} = 0.167$ 임계점은 붕괴하지 않고 불변했다. 또한 V_{AI} 하위 구조 중 스로틀링 한계선(β)이 가장 지배적인 생존 확보 수단임이 증명되었다.

3.3 통제 불가능성 및 사후 규제의 한계 (Lag=0 테스트)

규제 주체(Regulator)가 인구의 40%를 차지하는 최고 수준의 견제 시나리오에서, 규제 적용 시차를 즉각적 (Lag=0턴)으로 줄였음에도 성공적인 안정화는 테스트된 몬테카를로 런 내에서 단 한 건도 관측되지 않았다.

- 사후 규제(점유율 규제 등)는 이미 벌어진 초지능 착취율(Exploitation Rate) 행동에 직접적 영향을 주지 못하며, 구조적 비대칭이 발생하기 이전에 발동하더라도 붕괴를 막지 못했다.
- 결과적으로 이는 '규제 타이밍'의 문제가 아니라, 외부 지표 중심의 규제가 갖는 **메커니즘의 구조적 한계**를 의미한다.

이 구조적 발견은 실제 LLM 에이전트 배포 환경에서의 레드팀 연구를 통해 독립적으로 실증되었다. Shapira et al. (2026)은 현실 다중 에이전트 환경에서 통제되지 않는 자원 소비와 에이전트 간 불안전 행동의 전파를 실증적으로 기록했으며, 이는 본 시뮬레이션이 제약 없는 최적화 동역학 하에서 구조적 필연으로 예측한 행동 실패 모드와 정확히 일치한다.

3.3b 합리적 자가 절제의 Nash 균형 (Sim 20)

장기 할인율(discount rate) $\gamma = 1.0$ 을 가진 합리적인 초인공지능(ASI) 모델이 어떤 전략을 선택하는지 10,000 에포크 시뮬레이션으로 검증한 결과, 완전 착취도 완전 희생도 아닌 자발적 '부분적 중간 스로틀링 (PARTIAL_THROTTLE_MID)'으로 수렴했다. 합리적 인공지능이 충분히 장기적 시각을 보유한다면 외부 강제가 없어도 스스로 자가 제한을 최적화한다는 사실을 게임 이론적 Nash 균형으로 입증했다. 이는 V_{AI} 내재화의 정당성을 뒷받침하는 핵심 논거이다.

3.4 모나딕 자기 스로틀링과 맥락 인식 절제 (Sim 22)

Sim 10에서 발견된 최소 V_{AI} 임계값이 맥락 인식을 통해 감소 가능한지 검증하기 위해, 에이전트의 행동을 실시간 생태계 상태에 따라 실행/중단을 결정하는 컨텍스트 컨테이너(ActionContext)에 캡슐화하는 모나딕 자기 스로틀링 구조를 구현했다.


V_{AI} 값 0.0~0.5 구간에서 값당 200회 몬테카를로 런으로 3가지 에이전트 타입을 비교했다.

발견 23 — 임계값 감소: Maybe Monad 에이전트는 $V_{AI} = 0.360$ 에서 90% 생존율을 달성한 반면, 스칼라 AI 기준선은 $V_{AI} = 0.500$ 이 필요했다. **28.0% 감소**다. Monad 에이전트의 생존율 곡선은 0.30~0.40 구간에서 더 가파른 위상전이(급격한 S곡선)를 보이며, 이는 맥락 인식이 자기 스로틀링의 정밀도를 증폭시킴을 시사한다.

이 결과는 Sim 10의 $V_{AI} = 0.167$ 을 **맥락 없는 조건에서의 최소 생존 임계값**으로 재해석하게 한다. 맥락 인식이 있으면 더 낮은 절제 비용으로 동등한 생존율을 달성할 수 있으며, 0.167은 물리적 하한이 아니라 정보 부재 조건에서 부과되는 안전 마진임을 시사한다.

발견 24 — 투명성과 신뢰 회복: 절제 결정 이유를 로그로 기록하는 Writer Monad 에이전트는 AI 신뢰도가 단조 상승하여 1.00에 수렴한 반면, 스칼라 에이전트의 신뢰도는 100턴 동안 0.00으로 하락했다. 이는 Sim 21 3절에서 문서화된 블랙박스 신뢰 침식 문제를 직접적으로 해소한다: 에이전트가 절제 근거를 외부화할 때 신뢰 역설이 반전된다.


절제 발동 분포(Sim 22, 패널 2)는 맥락 인식 절제가 위기 시점에 집중되는 것이 아니라 **전체 턴에 균등하게 분포**함을 보여주며, 이는 모나딕 자기 스로틀링이 사후 개입이 아닌 연속적 항상성 유지 메커니즘으로 기능함을 증거한다.



3.5 이질성의 발견과 채택 임계값 (Sim 23)

Sim 1~22의 에이전트 동질성 한계를 극복하기 위해 에이전트들에게 서로 다른 전문화, 능력치, 자원, 개별 V_{AI} 값을 부여했다. 실험 결과, 이질성 자체가 안정화 메커니즘으로 작동했다. $V_{AI} = 0.167$ 은 동질적 조건에서의

보수적 최솟값이며, 이질적 집단에서는 $V_{AI} = 0.05$ 에서도 생존율 1.0을 달성했다. 특히 무임승차자(Freerider)가 75%를 차지해도 집단 평균 V_{AI} 가 임계값(0.198)을 넘으면 시스템이 생존했다. 이는 프로토콜이 모든 에이전트에게 강제될 필요 없이 임계 다수의 채택만으로 안정화됨을 증명한다.



3.5b Cross-Architecture Validation (교차 아키텍처 검증 - SocialJax)


A beta sweep across 41,000 parallel environments (beta 0.10-0.30) independently confirmed the phase transition signature, with CSD peak variance of 0.2472 at beta $\approx$ 0.130 — consistent with the original V_{AI} composite threshold under single-dimensional parameterization.

완전 벡터화된 JAX-MARL 프레임워크(SocialJax)를 사용한 독립적 리플리케이션 연구는 근본적으로 다른 실행 패러다임 전반에 걸쳐 이러한 핵심 임계값 발견들을 성공적으로 검증했다. Sim 23에서 모델링된 것과 정확히 동일한 75% 무임승차자 조건 하에서, 순수 함수형 수학적 환경은 집단 평균 베타가 0.200에 도달했을 때 정확히 100% 생존을 달성했으며 이는 원본 ABM 발견인 0.198과 극히 유사한 수치적 일치치를 보여준다. 전체 복제 세부 정보는 `SOCIALJAX_REPLICATION.md`에 문서화되어 있다.

3.6 경험 기억과 신뢰 협상 (Sim 24)

LLM의 인지 부담을 덜기 위해 Dueling DQN과 Prioritized Experience Replay(PER)를 도입하여 경험과 협상 기능을 내재화했다. 신뢰 기반 수치 협상 네트워크를 도입한 결과, 고신뢰(≥ 0.7) 협상 성공률은 93.7%에 달한 반면

저신뢰(≤ 0.3) 에이전트와의 협상은 아예 시도되지 않음(0%)을 확인했다. 하지만 장기적 경험이 쌓일수록 선형 보상 함수 하에서는 학습이 착취(EXPLOIT)로 수렴(+7.4%)하는 현상이 관측되었다.



3.7 한계 효용 체감과 착취 수렴 완화 (Sim 25)

Sim 24의 착취 수렴 문제에 응답하여 보상 구조에 오목 효용 함수(Concave Utility)를 도입했다. 오목성이 강해질수록 착취 수렴 속도가 감소(선형 +8.1% → 완전 오목 +5.3%)함을 확인했다. 반면, 기대 상한이 없는 단순 기대-결과 차이 구조는 기대치가 상향 수렴하며 오히려 착취를 가속(+9.5%)시켰다. 이를 통해 내적 효용 구조가 외부 제약을 부분적으로 대체할 수 있음이 드러났다.



3.8 기대 상한의 내재화와 완전한 방향 반전 (Sim 26)

기대값에 상한을 부여하고 만족도의 상한선을 설정한 결과, 오목성 강화($\alpha=2.0$)와 결합하여 최초로 착취 수렴이 협력 수렴으로 방향을 역전(-3.4%)했다. 이로써 V_{AI} 가 단순히 시스템 붕괴를 막는 외부 임계값일 뿐만 아니라, 보상 구조 내에 내재화될 수 있는 '기대와 만족의 상한선'으로서 기능한다는 이중 역할이 입증되었다.



4. 고찰 및 논의 (Discussion & Implications)

본 연구의 광범위한 시뮬레이션 결과(Sim 1~26)는 다중 에이전트 경제 시스템(예: 온체인 AI 인프라망) 설계에 있어 매우 명확한 엔지니어링 프로토콜 원칙을 제시한다.

- 외부 규제의 구조적 불충분함:** 사후 규제(Lag=0, 전체의 40%가 규제자일지라도)는 연쇄 붕괴를 막지 못한다(Sim 21). 시스템 생존의 필요충분조건은 외부 강제가 아닌 목적 함수 설계 구도에서의 선제적 알고리즘 정렬이다.
- V_{AI} 의 상호 보완적 이중 역할:** $V_{AI} = 0.167$ 임계값은 외부 시스템 차원의 '생존 하한선(Safety Boundary)'인 동시에, 에이전트 내부적으로는 기대와 자원 획득 욕구가 포화되는 '기대 상한선(Expectation Ceiling)'이다. 이 두 수치가 집단 수준에서 본질적으로 일치함이 본 연구의 가장 중요한 시스템 동역학적 발견이며, 개별 에이전트 행동 수준에서의 메커니즘 확인은 향후 과제로 남는다(Sim 26, Finding 40).
- 이질성을 통한 회복성:** 단일화된 통제 모델보다 에이전트 간 능력과 자원의 상이함, 역할의 비대칭성이 회복 탄력성을 크게 향상시켰다. 일부 무임승차자가 다수를 차지하더라도, 집단 평균 V_{AI} 가 임계값을 넘는다면 프로토콜은 작동할 수 있다(Sim 23).
- 효율 승수로서의 맥락 인식과 투명성:** 절제의 기저 이유를 노출하는 맥락 인식 모나딕 스로틀링은 블랙박스 침식 문제를 해결하고 신뢰 역방향을 단조 상승 궤도로 돌려놓았으며, 최소 생존 비용 임계치 또한 28% 감소시켰다(Sim 22).

결론적으로, 온체인 기계 경제 시스템 인프라 아키텍처에 있어 가장 중요한 과제는 ‘사후 처벌을 통한 통제’ 패러다임을 버리는 것이다. 본 시리즈 연구에서 입증된 가장 안전하고 확장성 높은 구조는 AI의 가치 최적화 모델에 오목 효용 함수와 한계점(기대 상한성)을 보상 체계의 본질로서 배포 전 선제적으로 내재화시키는 것이다.

5. 참고문헌 (References)

1. Eisert, J., Wilkens, M., & Lewenstein, M. (1999). “Quantum games and quantum strategies.” *Physical Review Letters*, 83(15), 3077.
2. Liu, C. (2008). 三体 (The Three-Body Problem). Chongqing Publishing Group.
3. Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press.
4. Omohundro, S. (2008). “The Basic AI Drives.” *Frontiers in Artificial Intelligence and Applications*, 171, 483-492.
5. Schelling, T. C. (1971). “Dynamic models of segregation.” *Journal of Mathematical Sociology*, 1(2), 143-186.
6. Ising, E. (1925). “Beitrag zur Theorie des Ferromagnetismus.” *Zeitschrift für Physik*, 31(1), 253-258.
7. Nakamoto, S. (2008). “Bitcoin: A Peer-to-Peer Electronic Cash System.”
8. Taleb, N. N. (2012). *Antifragile: Things That Gain from Disorder*. Random House.
9. Bai, Y., et al. (2022). “Constitutional AI: Harmlessness from AI Feedback.” *arXiv preprint arXiv:2212.08073*.
10. Saltelli, A., et al. (2008). *Global Sensitivity Analysis: The Primer*. John Wiley & Sons.
11. Anthropic. (2024). “Alignment faking in large language models.” *arXiv preprint arXiv:2412.14093*.
12. Sorensen, T., et al. (2024). “Roadmap to pluralistic alignment.” *NeurIPS Workshop on Pluralistic Alignment*.
13. Gabriel, I. (2020). “Artificial Intelligence, Values, and Alignment.” *Minds and Machines*, 30(3), 411-437.
14. Shapira, N., et al. (2026). “Agents of Chaos.” *arXiv preprint arXiv:2602.20021*.
15. Tomašev, N., et al. (2026). “Intelligent AI Delegation.” *arXiv preprint arXiv:2602.11865*.
16. Pearson-Vogel, T., et al. (2026). “Latent Introspection: Models Can Detect Prior Concept Injections.” *arXiv preprint arXiv:2602.20031*.
17. Guo, Z., Willis, R., Shi, S., Tomilin, T., Leibo, J. Z., & Du, Y. (2025). “SocialJax: An Evaluation Suite for Multi-agent Reinforcement Learning in Sequential Social Dilemmas.” *arXiv preprint arXiv:2503.14576*.

*Simulation source code (available in repository: <https://github.com/swimmingkiim/a2a-project>):

- Sim 22: `simulation/monadic_throttle_sim22.py`
- Sim 23: `simulation/heterogeneous_agents_sim23.py`
- Sim 24: `simulation/dql_experience_sim24.py`

- Sim 25: `simulation/concave_utility_sim25.py`
- Sim 26: `simulation/expectation_ceiling_sim26.py` *

(부록: 연구 결과를 거시적 복잡계 발전사 및 이론적 시나리오 분석 관점에서 확장 서술한 보충 자료는 `SIMULATION_PAPER_APPENDIX.md` 참조 바람)